GENERATIVE AI BASICS · LECTURE 02

거대 언어 모델(LLM)과 기반 모델의 탄생

Foundation Model · LLM · Scaling Law · Emergence



01 02 03 04 05

생성형 AI 기초 · 10–15분

지난 시간 → 오늘

챗GPT는 어떻게 이렇게 똑똑해졌을까?

1강 복습

생성형 AI = 새로운 콘텐츠를 만드는 AI.
그 바탕에는 **기반 모델(Foundation Model)**이 있다.

01 **엄청난 양의 글을 미리 읽었다**
사전 학습

02 **엄청나게 큰 모델이 되었다**
파라미터 · 스케일링 법칙

03 **'다음 단어 맞히기'가 생각보다 강력했다**
창발성

FOUNDATION MODEL

기반 모델은 한 번 크게 배워 여러 곳에 쓴다



① 대규모 데이터로 학습

② 한 번 학습해 재사용

③ 다양한 작업에 적응

LARGE LANGUAGE MODEL

LLM은 텍스트에 특화된 기반 모델이다

텍스트

LLM · 거대 언어 모델

글을 읽고 쓰는 데 특화

예: GPT, Claude, Gemini, Llama

이미지

이미지 생성 모델

문장 → 그림

예: Stable Diffusion, Imagen

여러 형태

멀티모달 모델

텍스트 + 이미지 + 음성을 함께

예: 최신 GPT · Claude · Gemini

Large의 의미 → 파라미터 수십억~수천억 개 + 학습 데이터 수조 토큰

흐름 → 텍스트 LLM으로 출발해, 이미지·음성까지 다루는 멀티모달로 확장 중

PRE-TRAINING

사전 학습은 ‘다음 단어 맞히기’를 끝없이 반복한다

1단계 · PRE-TRAINING

사전 학습

방대한 텍스트로 다음 단어 맞히기를 반복

비유: 도서관 전체를 읽은 학생

2단계 · POST-TRAINING

사후 학습

모범 답안 예시와 사람의 피드백(RLHF)으로 다듬기

비유: 면접·실무 연습까지 마친 학생

AI 어시스턴트

챗GPT · Claude · Gemini

핵심: 사람이 정답을 일일이 달지 않아도, 글 자체가 ‘다음 단어’라는 정답을 품고 있다 → 학습 데이터를 거의 무한히 늘릴 수 있었다.

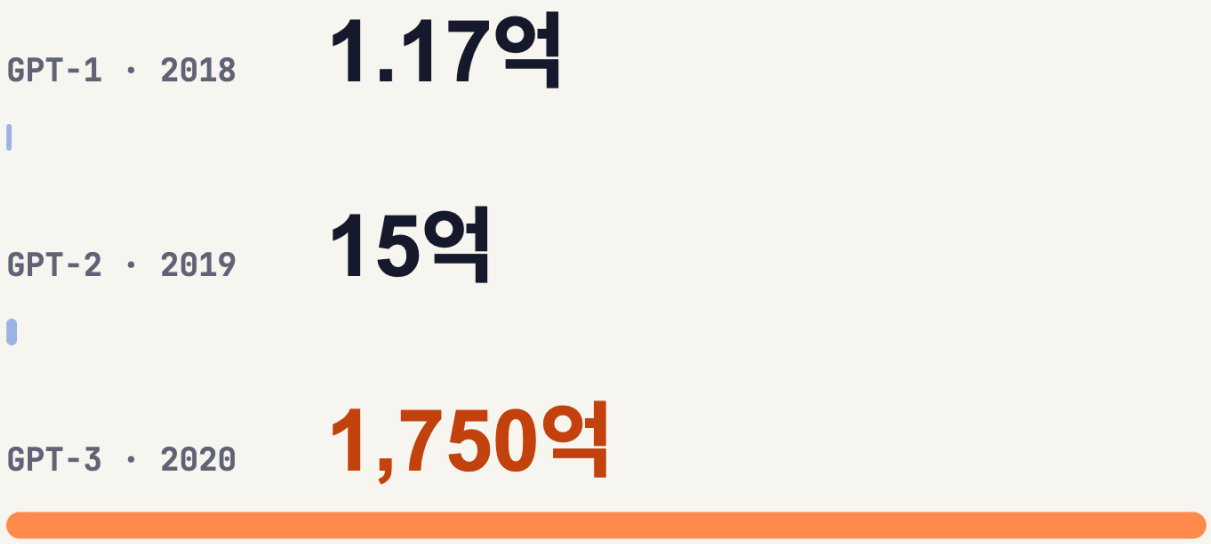
PARAMETER

파라미터는 모델 안의 조절 다이얼이다

학습 = 수많은 다이얼을 조금씩 돌려 정답에 가까워지는 과정

파라미터(가중치)는 모델 안의 숫자 하나하나다. 많을수록 더 복잡한 패턴을 담을 수 있다.

2년 만에 약 1,500배

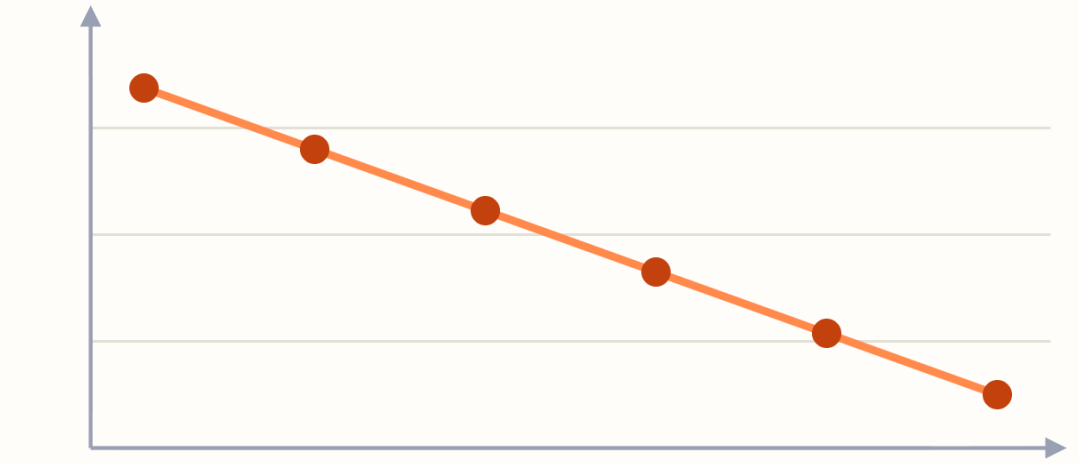


막대 길이 ≈ 실제 비율

출처: OpenAI 논문(2018·2019·2020). 최신 모델 상당수는 정확한 파라미터 수를 공개하지 않는다.

SCALING LAW

규모를 키우면 성능이 예측 가능하게 좋아진다



개념도 — 실제 측정값이 아님

세 가지 레버

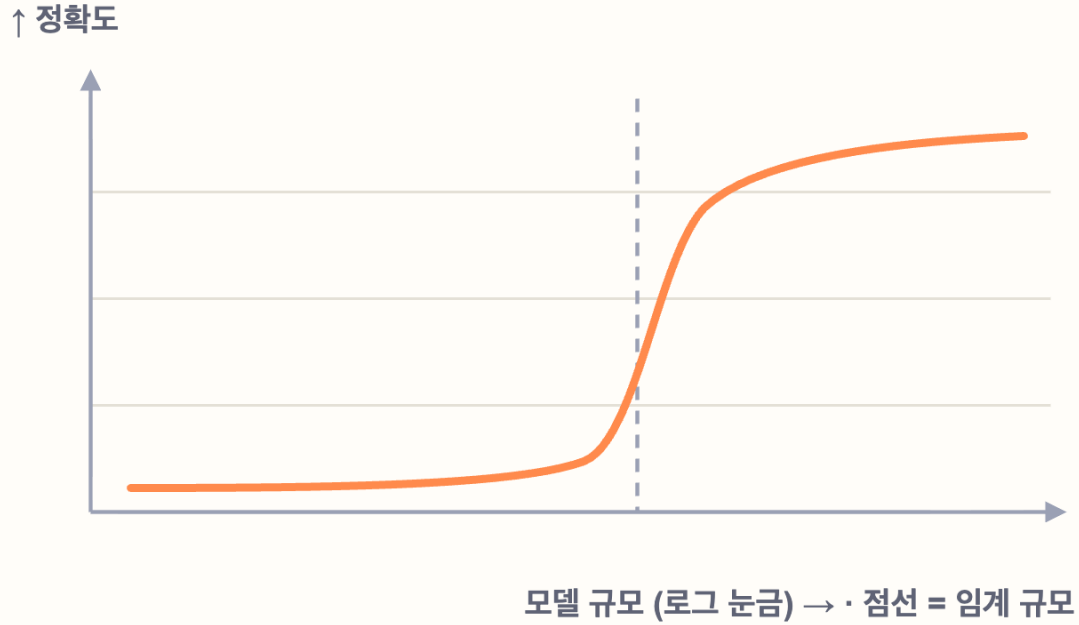
- **모델 크기 · 파라미터 수**
- **데이터 양 · 학습 토큰 수**
- **연산량 · GPU 학습 시간**

2020 · OpenAI — 세 가지를 키우면 오차가 거듭제곱 법칙을 따라 꾸준히 줄어든다

2022 · DeepMind (Chinchilla) — 모델만 키우기보다 데이터를 함께 늘리는 것이 효율적이다

EMERGENCE

어느 규모를 넘으면 새 능력이 '창발'한다



개념도 — 실제 측정값이 아님

규모가 커지자 나타난 능력 (예)

- ☆ **여러 자리 수 계산**
- ☆ **단계별로 풀어 쓰는 추론 (Chain-of-Thought)**
- ☆ **예시 몇 개만 보고 새 작업 수행 (Few-shot)**

반론도 있다

평가 방식을 바꾸면 '갑자기'가 아니라 서서히 좋아진 것으로 보인다는 연구(2023). 창발은 지금도 연구 중인 주제다.

NEXT WORD → REASONING

다음 단어를 잘 맞히려면 세상을 압축해야 한다

지식

대한민국의 수도는 ____

→ **서울**

사실을 알아야 맞힌다

논리 · 계산

사과 5개 중 2개를 먹으면 남은 사과는 ____개

→ **3**

계산을 해야 맞힌다

코드

```
def add(a, b):
    return ____
```

→ **a + b**

코드 구조를 알아야 맞힌다

+ 사후 학습과 '단계적으로 생각하기'가 더해져 → 추론·코딩 능력이 크게 향상

KEYWORDS

오늘의 키워드 6

Foundation Model

기반 모델

대규모 데이터로 한 번 학습해 다양한 작업에 적응하는 모델

Large Language Model

거대 언어 모델 (LLM)

텍스트를 읽고 쓰는 데 특화된 기반 모델

Pre-training

사전 학습

방대한 텍스트로 다음 단어 맞히기를 반복하는 첫 학습 단계

Parameter

파라미터

학습으로 조정되는 모델 안의 숫자(가중치), 모델 크기의 단위

Scaling Law

스케일링 법칙

모델·데이터·연산을 키우면 성능이 예측 가능하게 좋아지는 경향

Emergence

창발성

일정 규모를 넘으면 새로운 능력이 나타나는 현상

KEY MESSAGE

챗GPT·Gemini는 거대한 데이터를 미리 학습한 기반 모델이고, 그중 텍스트에 특화된 것이 LLM이다.

NEXT · LECTURE 03

생성형 AI가 실제로 동작하는 방식

AI는 정말 문장을 '이해'할까?